哈工大操作系统-L5系统调用的实现

本节课讲接口是如何实现的。即操作系统是怎么样来提供这些重要的函数的。

1. 不能随意访问内核

1.1 为何

如果能随意访问，那所有程序都可以随意访问存在内存中其他程序的数据，不安全。因此不能随意jump。

1.2 内核用户态/内核用户段

硬件设计将内核程序和用户程序隔离

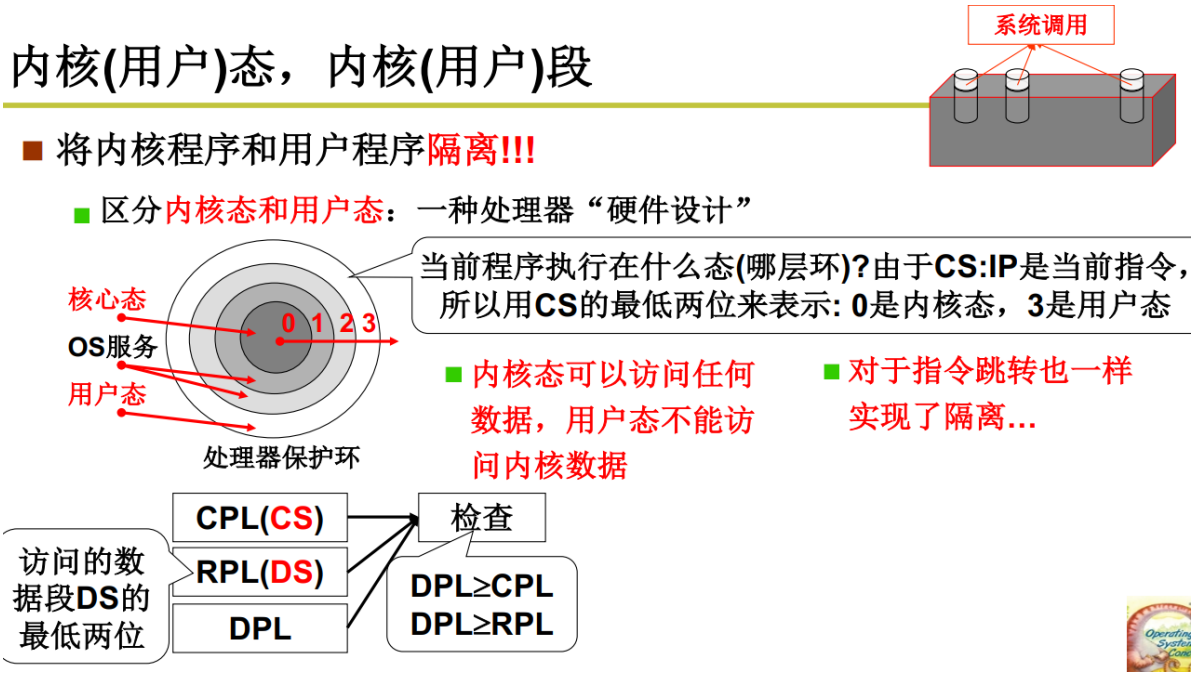

- **内存分为：内核段和用户段。**
- **指令执行的状态分为：内核态和用户态**
- 数据段中会记录该段是内核段还是用户段。(gdt表中的ds的dpl为0/3)

    - **保护**: 想要访问数据时，会根据指令找gdt去找数据，然后系统会核查dpl和cpl的关系，来保护内存段。
- 当前的指令也会记载目前是处于内核态还是用户态。(cs的cpl为0/3)
- 只有内核态可以访问任何数据。用户态访问不了内核段。

1.3 中断(硬件提供的主动请求进入内核的方法)

中断：用户主动调用内核代码的唯一方式.

对于x86cpu即为INT指令，INT指令执行前,先将该INT代码的数据的DS的DPL改为3，以允许用户代码通过idt找到该INT中断以进入内核;然后又将进入内核的代码的CPL改为0，以允许对内核的访问。一般为INT0x80.

1.3.1 系统调用的核心

- 用户程序中包含一段包含int指令的代码(这段代码一般是库函数)
- 操作系统写中断处理，获取想调程序的编号
- 操作系统根据编号执行相应代码

1.3.2 以pintf为例子

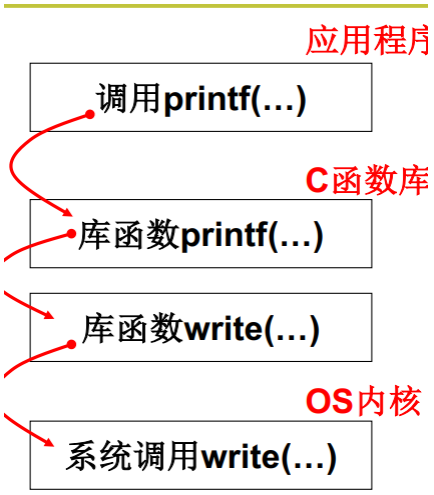

- 用户写程序时使用库函数printf()
- 而printf()中封装了另一个库函数write() (write()包含一段用宏展开的内嵌汇编代码)
- printf()和write()，将用户输入的格式化输出参数，转变为系统调用write()可以接受的参数。进而调用接口write()

1.3.3 write()如何实现

将关于write的故事完整的讲完...

_syscall3表示有3个参数

```
在linux/include/unistd.h中
#define _syscall3(type,name,atype,a,btype,b,ctype,c)\
type name(atype a, btype b, ctype c) \
{  long __res;\
__asm__ volatile("int 0x80":"=a"(__res):""(__NR_##name),
"b"((long)(a)),"c"((long)(b)),"d"((long)(c))); if(__res>=0) return
(type)__res; errno=-__res; return -1;}
```

返回值

赋值

这一句会展开成__NR_write
由根据宏定义，这个
__NR_write是4
因此会将4放入eax寄存器中

- 显然，__NR_write是系统调用号，放在eax中

```
在linux/include/unistd.h中
#define __NR_write 4 //一堆连续正整数(数组下标,
函数表索引)
```

- 同时eax也存放返回值，ebx，ecx，edx存放3个参数

- write()中包含一段由宏定义展开的内嵌汇编代码, 使用INT0X80中断进入内核，并传入中断号4。

1.3.4 INT0X80干了什么

调用相应的中断处理程序。

int 0x80中断的处理

```
void sched_init(void)
{ set_system_gate(0x80,&system_call); }
```

- 显然，set_system_gate用来设置0x80的中断处理

```
在linux/include/asm/system.h中
#define set_system_gate(n, addr) \
_set_gate(&idt[n],15,3,addr); //idt是中断向量表基址
#define _set_gate(gate_addr, type, dpl, addr)\
__asm__("movw %%dx,%%ax\n\t" "movw %0,%%dx\n\t"\
"movl %%eax,%1\n\t" "movl %%edx,%2":\
:"i"((short)(0x8000+(dpl<<13)+type<<8))),"o"(*(( \
char*)(gate_addr))),"o"(*(4+(char*)(gate_addr))),\
"d"((char*)(addr)),"a"(0x00080000))
```

4	处理函数入口点偏移	P	DPL	01110	
0	段选择符	处理函数入口点偏移			

中断处理程序: system_call

```
在linux/kernel/system_call.s中
nr_system_calls=72
.globl _system_call
_system_call: cmpl $nr_system_calls-1,%eax
   ja bad_sys_call
   push %ds  push %es  push %fs
   pushl %edx  pushl %ecx  pushl %ebx  //调用的参数
   movl $0x10,%edx  mov %dx,%ds  mov %dx,%es //内核数据
   movl $0x17,%edx  mov %dx,%fs  //fs可以找到用户数据
   call _sys_call_table(,%eax,4) //a(,%eax,4)=a+4*eax
   pushl %eax //返回值压栈，留着ret_from_sys_call时用
   ... //其他代码
ret_from_sys_call: popl %eax, 其他pop, iret
```

eax中存放的是系统调用号

```
__asm__ volatile("int 0x80":"=a"(__res)
```

内核的代码段

- _sys_call_table+4*%eax就是相应系统调用处理函数入口

每个入口函数占4个字节

_sys_call_table

```
在include/linux/sys.h中
fn_ptr sys_call_table[]=
{sys_setup, sys_exit, sys_fork, sys_read, sys_write,
  ...};
在include/linux/sched.h中
typedef int (fn_ptr*)();
```

sys_call_table是一个全局函数数组

sys_write对应的数组下标为4，__NR_write=4

这段代码可以找到sys_write的中断处理函数

- call _sys_call_table(,%eax,4)就是call sys_write

eax=4，函数入口地址长度也为4

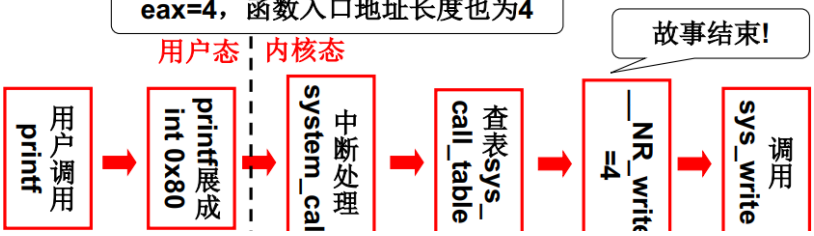

- 可以认为sys_write是一个系统接口

2. 总结

- 为了保护数据，将内核数据和用户数据分开。指令分成内核态和数据态，内存分为内核段和数据段。
  - 只有内核态可以访问所有数据
- 因为隔离开，所以用户只能通过中断来主动进入内核。如INT0x80中断。
- 用户主动进入内核的流程为：
  - 写一段包含库函数的代码
  - 库函数中封装了使用宏展开的汇编代码，汇编代码中包含INT0X80中断
  - 执行库函数后，系统进入中断，然后去执行中断处理函数
    - INT0x80的执行过程中，为了让用户执行这个中断，会在中断的执行之前将0x80的idt表设置为用户段，因此用户能访问中断的程序，进而执行这个中断。

- 中断处理函数会去查表，执行相应的系统接口。比如INT0X80的4号中断，就是表中的4号系统接口system_write